

<http://dx.doi.org/10.17703/JCCT.2020.6.4.789>

JCCT 2020-11-100

딥 러닝 기반 코로나19 흉부 X선 판독 기법

A COVID-19 Chest X-ray Reading Technique based on Deep Learning

안경희*, 엄성용**

Kyung-Hee Ann*, Seong-Yong Ohm**

요약 전 세계적으로 유행하는 코로나19로 인해 많은 사망자가 보고되고 있다. 코로나19의 추가 확산을 막기 위해서는 의심 환자에 대해 신속하고 정확한 영상판독을 한 후, 적절한 조치를 취해야 한다. 이를 위해 본 논문은 환자의 감염 여부를 의료진에게 제공해 영상판독을 보조할 수 있는 딥 러닝 기반 코로나19 흉부 X선 판독 기법을 소개한다. 우선 판독모델을 학습하기 위해서는 충분한 데이터셋이 확보되어야 하는데, 현재 제공하는 코로나19 오픈 데이터셋은 학습의 정확도를 보장하기에 그 영상 데이터 수가 충분하지 않다. 따라서 누적 적대적 생성 신경망(StackGAN++)을 사용해 인공지능 학습 성능을 저하하는 영상 데이터 수적 불균형 문제를 해결하였다. 다음으로 판독모델 개발을 위해 증강된 데이터셋을 사용하여 DenseNet 기반 분류모델 학습을 진행하였다. 해당 분류모델은 정상 흉부 X선과 코로나19 흉부 X선 영상을 이진 분류하는 모델로, 실제 영상 데이터 일부를 테스트데이터로 사용하여 모델의 성능을 평가하였다. 마지막으로 설명 가능한 인공지능(eXplainable AI, XAI) 중 하나인 Grad-CAM을 사용해 입력 영상의 질환 유무를 판단하는 근거를 제시하여 모델의 신뢰성을 확보하였다.

주요어 : 코로나19, 흉부 X선, StackGAN++, 설명 가능한 인공지능, 이진 분류

Abstract Many deaths have been reported due to the worldwide pandemic of COVID-19. In order to prevent the further spread of COVID-19, it is necessary to quickly and accurately read images of suspected patients and take appropriate measures. To this end, this paper introduces a deep learning-based COVID-19 chest X-ray reading technique that can assist in image reading by providing medical staff whether a patient is infected. First of all, in order to learn the reading model, a sufficient dataset must be secured, but the currently provided COVID-19 open dataset does not have enough image data to ensure the accuracy of learning. Therefore, we solved the image data number imbalance problem that degrades AI learning performance by using a Stacked Generative Adversarial Network(StackGAN++). Next, the DenseNet-based classification model was trained using the augmented data set to develop the reading model. This classification model is a model for binary classification of normal chest X-ray and COVID-19 chest X-ray, and the performance of the model was evaluated using part of the actual image data as test data. Finally, the reliability of the model was secured by presenting the basis for judging the presence or absence of disease in the input image using Grad-CAM, one of the explainable artificial intelligence called XAI.

Key words : COVID-19, Chest X-ray, StackGAN++, XAI, Binary Classification

*준회원, 서울여자대학교 소프트웨어융합학과 학부생(제1저자) Received: October 22, 2020 / Revised: November 06, 2020

**정회원, 서울여자대학교 소프트웨어융합학과 교수(교신저자) Accepted: November 14, 2020

접수일 : 2020년 10월 22일, 수정완료일: 2020년 11월 06일 *Corresponding Author: osy@swu.ac.kr

게재확정일: 2020년 11월 14일

Dept. of Software Convergence, Seoul Women's Univ, Korea

I. 서 론

최근 집단 폐렴 원인 병원체인 코로나바이러스감염증-19(코로나19, COVID-19)가 전 세계로 확산되면서 확진자가 약 4000만 명, 사망자가 약 100만 명을 넘어섰다. 확진자와 사망자가 기하급수적으로 증가함에 따라 의료진 수 및 의료시설 부족 문제를 해결할 방법과 전염 확산 방지를 위해 조기 의심 환자에 대한 신속하고 정확한 진단 방법의 필요성이 대두되고 있다.

폐 질환을 진단하기 위한 대표적인 검사로는 흉부 X선과 흉부 전산화단층촬영(CT)이 있다. 흉부 X선 검사는 다른 검사들보다 비교적 저렴한 검사 비용과 단시간 촬영, 적은 방사선 피폭량이라는 장점으로 인해 흉부 검사 중 가장 사용 빈도가 높다. 그러나 영상판독은 의료진별 역량이나 경험, 시각적 인지 능력의 편차로 인해 진단 결과가 달라질 수 있고, 반복적이고 시간 소모적인 문제가 있다[1]. 최근 ICT 기술이 발전함에 따라 위와 같은 문제들을 해결하고자 인공지능[2]을 활용한 흉부 X선 영상판독 연구들[3]이 활발히 진행되고 있다.

인공지능 모델 학습 시 데이터 수 부족과 불균형 문제는 모델 학습 성능 저하의 주요인이 되기 때문에 모델을 잘 학습시키기 위해서는 균형 있는 적절한 데이터 수가 확보되어야 한다[4]. 하지만 현재 코로나19 감염 환자 수에 비해 진단 영상 확보율은 상당히 낮은 상황으로 학습에 필요한 코로나19 영상 데이터 수는 현저히 부족하다.

이러한 문제를 해결하고자 본 논문에서는 실제와 똑같은 가짜 영상 데이터들을 생성하는 데이터 증강 기법의 하나인 누적 적대적 생성 신경망(StackGAN++)[5]을 사용하여 부족한 코로나19 영상 데이터 수를 보강하였고, 증강 영상을 기반으로 판독모델을 학습하였다.

한편, 인공지능이 도입된 이후 인공지능 판단에 대한 이유를 사람이 이해할 수 있는 방식으로 제시하는 것에 대한 필요성이 있었다. 이 문제는 특정한 판단에 대해 알고리즘의 설계자조차도 그 이유를 설명할 수 없다는 ‘블랙박스’ 문제라고 불리는데, 특히 의료 분야에서는 인공지능의 결과가 환자의 생명과 직접 연관되기 때문에 어떤 근거를 가지고 결과를 도출하였는지에 대한 판단의 설명이 필수적이다.

최근 블랙박스 문제와 대비되는 개념인 설명 가능한 인공지능(explainable Artificial Intelligence, XAI)[6]이 소개되었고, 결과에 대한 해석 가능성을 확보하여 모델

의 신뢰성을 높이는 데 이바지하였다.

따라서 본 논문에서는 코로나19 확산을 방지하고자 환자의 감염 여부와 판단 근거를 시각화한 결과를 의료진에게 제공해 영상판독을 보조하는 딥 러닝 기반 코로나19 흉부 X선 판독 기법을 제안한다.

II. 관련 연구

2.1. GAN

Ian Goodfellow et al.에 의해 처음 발표된 적대적 생성 신경망(Generative Adversarial Network, GAN)[7]은 실제 같은 가짜 데이터를 만드는 생성자(generator)와 가짜 데이터의 진위를 판단하는 판별자(discriminator)가 적대적으로 학습하는 인공지능 알고리즘이다. 적대적 생성 신경망은 확률모델을 정확하게 정의하지 않아도 어떤 분포 혹은 분산 자체를 만들어내기 때문에 해당 분포로 가짜 데이터를 생성할 수 있다. 하지만 초기 모델은 생성자와 판별자가 대립하며 학습하기 때문에 학습이 불안정하다는 단점이 있었다.

이후 적대적 생성 신경망 개념에서 파생한 다른 모델들이 많이 소개되었는데, 그중 심층 합성곱 적대적 생성 신경망(Deep Convolutional GAN, DCGAN)[8]은 학습 시 발생하는 불안정성을 개선하고자 도입된 개념으로, 합성곱(Convolution)을 기존 적대적 생성 신경망에 추가한 것이다. 그러나 해당 네트워크는 학습의 안정성을 확보하였지만, 저해상도의 영상을 생성한다는 한계가 있다.

저해상도 영상생성 문제를 해결하기 위해 최근까지도 고해상도 영상생성에 관한 연구들이 많이 이뤄지고 있다. 대표적으로는 점진적 증가 적대적 생성 신경망(Progressive Growing GAN, PGGAN)[9]과 스타일 생성 신경망(StyleGAN)[10]이 있는데 이 두 네트워크는 생성자와 판별자의 네트워크층을 점진적으로 쌓아 영상의 해상도를 점차 증가시키는 방식으로 학습을 진행한다. 이렇게 점진적으로 층을 늘려 학습을 하게 되면 저해상도의 영상에서 나타나는 전반적인 영상구조의 특징뿐만 아니라, 고해상도 영상의 세부적인 정보를 모두 반영하여 영상을 생성할 수 있다는 장점이 있다.

다시, 적대적 생성 신경망 개념으로 돌아가서 기존 네트워크의 경우 질환의 특징이 달라지면 네트워크를 질환별로 개별 학습해야 하는 문제가 있었다. 따라서

이를 해결하기 위해 네트워크 학습 시 생성자와 판별자의 입력으로 조건변수(condition)를 넣어주는 조건부 적대적 생성 신경망(conditional GAN, cGAN)[11]이라는 개념이 나오게 되었다. 이는 한 번의 네트워크 학습만으로 결과를 제어할 수 있다는 장점이 있어 Pix2Pix[12]과 CycleGAN[13]으로 확장되어 다양한 연구에 많이 적용되고 있다.

2.2. DenseNet

Gao Huang et al.에 의해 제안된 DenseNet[14]은 조밀하게 연결된 합성곱 신경망(Convolutional Neural Network, CNN)[15][16] 구조를 갖는다. 즉, 각 층은 이전의 모든 층에서 나온 특징 맵(feature map)을 입력으로 받으며 자신의 출력 특징 맵을 이후에 쌓인 모든 층에 전달하는 형태를 갖는다. DenseNet과 많이 비교되는 네트워크로는 ResNet[17]이 있는데 ResNet은 이전 층들의 특징 맵을 계속해서 다음 층의 입력과 더하는(sum) 방식으로 네트워크가 설계되어있다. 표면적으로 DenseNet은 ResNet과 매우 유사하지만, DenseNet은 입력을 이어붙임(concatenation)으로써 모든 층에서 학습된 특징 맵을 모든 후속 층에서 접근 할 수 있다는 점이 다르다.

이렇게 조밀하게 연결된 패턴은 전통적인 합성곱 신경망보다 파라미터 수를 절감할 수 있으며, 중복된 특징 맵을 재학습할 필요가 없어진다. 그뿐만 아니라 기울기가 사라지는 기울기 소실(vanishing gradient)문제를 방지해 학습을 수월하게 한다.

III. 시스템 구성 및 적용 모델

3.1. StackGAN++ 기반 영상 증강

Han Zhang et al.에 의해 제안된 StackGAN++[5]은 고해상도 영상생성과 결과 제어가 가능한 네트워크이다. 우선, StackGAN++은 그림 1과 같이 총 3개의 블록으로 나누어져 있으며, 블록별로 업샘플링(upsampling) 과정을 진행하여 저해상도부터 고해상도 영상생성까지를 단계별로 수행한다. 3개의 블록 중 첫 번째 블록은 4개의 3x3 합성곱으로 이루어져 있으며 저해상도 영상(64x64)을 생성한다. 두 번째 블록과 마지막 블록은 이전 블록에서 생성된 것을 연결하는 1개의 결합(joining) 층과 2개의 잔여(residual) 층 그리고 1개의 3x3 합성곱 층으로 구성되며, 각 블록은 중간 해상도 영상(128x128)과 고해상도 영상(256x256)을 생성한다. 저해상도 영상 학습 시 전역적인 영상의 특징을 얻고, 고해상도 영상 학습 시 저해상도 영상 학습 후 얻은 구조적인 특징 위에 세부적인 특징을 추가하여 보정한다. 따라서 이렇게 단계별로 영상을 생성하는 것은 전역적, 지역적 특징을 모두 반영한 고해상도 영상을 얻을 수 있도록 한다. 즉, StackGAN++은 의료 분야에서 활용이 가능한 수준의 고해상도 영상을 생성할 수 있다.

두 번째로 StackGAN++은 하나의 신경망으로 다수의 질환 영상 학습이 가능하다. 기존 적대적 생성 신경망은 단일 클래스의 영상만 생성할 수 있어 정상과 비정상 영상의 데이터를 생성하기 위해서는 각각 신경망을 학습시켜야 했다. 반면, StackGAN++은 생성자에 입

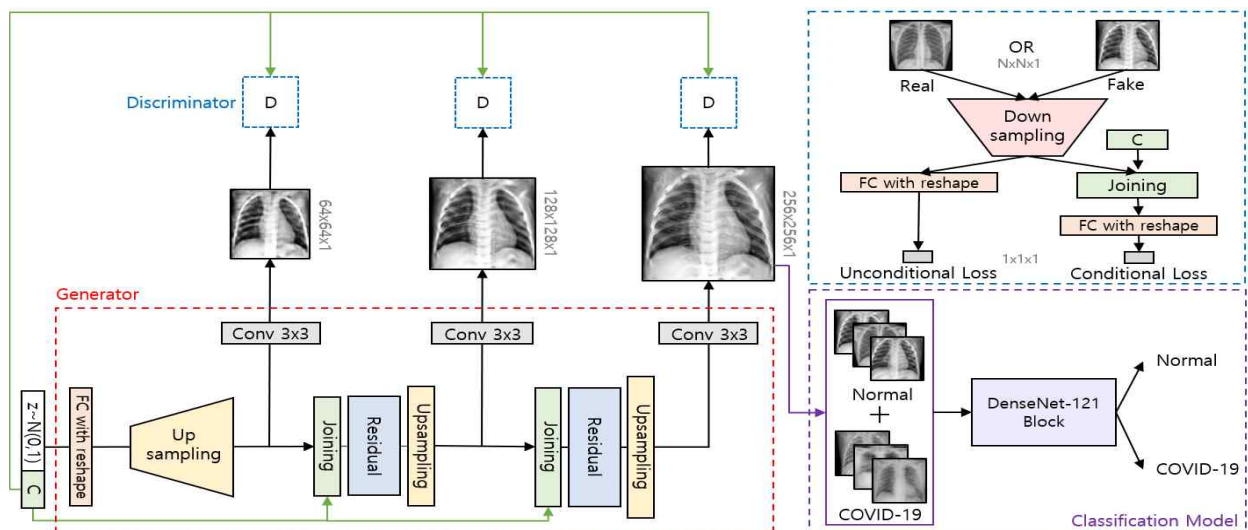


그림 1. StackGAN++과 DenseNet-121 모델

Figure 1. StackGAN++ and DenseNet-121 Models

력으로 노이즈($Z \sim N(0,1)$)와 함께 질환 조건 제어인자인 조건변수 c 를 넣고, 판별자에 영상(실제 영상 혹은 생성 영상)과 조건변수 c 를 추가하여 한 번의 학습만으로 원하는 질환 생성이 가능하다.

따라서 본 논문에서는 StackGAN++을 사용하여 질환마다 네트워크를 별도로 학습해야 하는 문제를 해결하여 보다 효율적이게 고해상도 영상을 생성하였다.

3.2. DenseNet 기반 영상 분류

논문에서 제안하는 판독모델은 StackGAN++ 기반으로 증강된 영상과 실제 영상을 입력으로 받아 정상 환자와 코로나19 감염 환자를 분류하는 이진 분류모델이다 (그림 1). 해당 판독모델은 흉부 X선 14개의 질환을 판독하는 Pranav Rajpurkar et al.이 제안한 CheXNet[18]에서 아이디어를 차용하여, 121개 층으로 구성된 DenseNet(DenseNet-121)[14]으로 학습을 진행하였다. DenseNet-121은 4개의 조밀한(dense) 블록과 3개의 전이(transition) 층으로 구성되어 있다. 각 블록은 1×1 합성곱과 3×3 합성곱을 쌓으로 하여 6, 12, 24, 16번 반복하는 구조로 되어있다. 그리고 각 블록 사이에는 1×1 합성곱과 평균 풀링(average pooling)을 수행하는 전이 층이 들어가 4개의 블록을 연결한다.

IV. 시스템 학습

4.1. 데이터셋

본 논문에서는 데이터 증강을 위해 Kaggle에서 수집한 코로나19 흉부 X선 영상 데이터셋을 사용한다. 데이터셋은 정상 흉부 X선 영상 2,483장과 코로나19 흉부 X선 영상 354장으로 구성된다.

4.2. StackGAN++ 학습

Kaggle에서 수집한 데이터셋은 정상 흉부 X선과 코로나19 흉부 X선 영상 간의 데이터 수적 불균형 문제가 존재한다. 이를 해결하기 위해 본 논문에서는 StackGAN++을 사용해 영상 데이터를 증강하였다. 구체적으로 배치 사이즈 16, 에폭 600, 학습률(learning rate)은 판별자의 경우 0.00002, 생성자의 경우 0.00002를 설정하여 모델 학습을 수행하였다.

4.3. 코로나19 판독모델 학습

코로나19 판독모델을 개발하기 위해 본 논문에서는 DenseNet 기반으로 이진 분류모델을 학습하였다. 구체적으로 배치 사이즈 16, 에폭 90, 학습률 0.001, 감마 0.1로 설정하여 모델 학습을 수행하였다. 또한, 학습 데이터와 실험 데이터는 8대 2로 하였다.

V. 적용 결과

5.1. StackGAN++ 결과

5.1.1. 영상 증강 결과

StackGAN++을 사용하여 정상 흉부 X선 영상 2,517장과 코로나19 흉부 X선 영상 4,646장을 추가로 생성해 영상 데이터를 증강하였다. 따라서, 각 5,000장씩 총 10,000장의 영상을 확보하여 데이터 불균형 문제를 해결하였다. 표 1은 StackGAN++ 사용 전후에 따른 영상 수를 정리한 것이다.

표 1. StackGAN++ 사용 전후에 따른 영상 수
Table 1. Number of Image Before and After Using StackGAN++

	증강 전 영상 수	증강 후 영상 수
Normal	2,483	5,000
COVID-19	354	5,000

5.1.2. 생성자, 판별자 손실 그래프

그림 2는 StackGAN++의 생성자와 판별자가 안정적으로 학습되어있는지 확인하기 위한 손실 그래프이다. 그림 2의 x축은 반복(iteration), y축은 손실(loss)을 의미하며, 생성자와 판별자 모두 특정 값으로 수렴하는 것을 확인할 수 있다. 이를 통해 학습이 안정화된 것을 확인할 수 있다.

5.1.3. 정성적 평가

표 2는 StackGAN++으로 증강한 정상 흉부 X선과 코로나19 흉부 X선 영상을 실제 영상과 비교한 것이다. 코로나19 영상은 양쪽 폐의 가쪽에 불균일한 음영이 분포하는 특징을 보인다.









그림 2. 생성자(왼쪽)와 판별자(오른쪽) 손실 그래프
Figure 2. Generator(Left) and Discriminator(Right) Loss Graph

따라서 StackGAN++으로 증강한 영상들도 이러한 특징을 포함하고 있으므로 잘 증강되었다고 볼 수 있다.

표 2. StackGAN++으로 증강한 영상과 실제 영상 비교
Table 2. Comparison of Images Augmented with StackGAN++ and Actual Images

	실제 영상	증강 영상
Normal		
COVID-19		

x)을 통해 계산된 분류 성능 지표인 정확도(accuracy), AUC, 민감도 그리고 특이도로 구성되어 있으며, 각 지표 모두 1에 가깝게 수렴하는 것을 확인할 수 있다.

표 3. 코로나19 판독모델 분류 성능 평가 결과
Table 3. COVID-19 Reading Model Classification Performance Evaluation Results

	판독모델 분류 성능
ACC	0.98
AUC	0.981192
Sensitivity	0.971569
Specificity	0.990816

또한, 그림 3은 표 3을 기반으로 ROC 곡선을 나타낸 것이다. 곡선 아래 면적이 넓을수록 분류 성능이 높은 것을 의미한다. 즉, 그림 3과 표 3을 통해 분류모델의 성능이 좋은 것을 확인할 수 있다.

5.2. 코로나19 판독모델 결과

5.2.1. 분류 성능 평가

분류의 성능은 참값의 정답을 참이라고 예측한 민감도(sensitivity)와 거짓값의 정답을 거짓이라고 예측한 특이도(specificity)로 평가한다. 또한, 민감도와 특이도를 복합적으로 표현하기 위해 ROC 곡선을 사용한다. 그래프에서 x축은 1-특이도, y축은 민감도이고 곡선 아래의 2차원 면적은 AUC(Area Under ROC Curve)라 한다. AUC의 크기는 0.5에서 1을 가질 수 있는데 값이 1에 가까울수록 안정된 모델이라고 할 수 있다.

표 3은 DenseNet 기반의 이진 분류모델 성능 평가 결과를 나타낸 표이다. 표는 오차 행렬(confusion matrix)




그림 3. ROC 곡선
Figure 3. ROC Curves

5.2.2. 설명 가능한 인공지능

설명 가능한 인공지능(eXplainable Artificial Intelligence, XAI)[6]은 인공지능이 문제를 잘 맞히지만, 어떻게 잘 맞히는지 그 원리를 알기 힘들다는 점을 해결하기 위해 고안된 개념이다. 즉, 설명 가능한 인공지능으로 결과에 대한 근거 있는 해석을 제공하여 현재 딥 러닝 모델 대부분이 가지고 있는 블랙박스 문제를 해결할 수 있다.

특히 의료 분야에서는 판단에 대해 의미 있는 해석을 도출하는 과정이 더욱 중요하다. 왜냐하면, 해당 분야의 특성상 환자의 생명과 직접 관련이 있으므로 딥 러닝 모델의 정확도가 아무리 높아도 판단오류의 가능성을 무시하기 어렵기 때문이다.

따라서 근거를 시각화하는 것은 모델에 문제가 생겼을 때, 과정을 추적하여 오류를 보다 쉽게 찾을 수 있고 모델의 신뢰성을 높일 수 있다. 본 논문에서는 DenseNet 기반으로 학습한 판독모델에 영상 데이터가 들어왔을 때, Grad-CAM[19]을 사용하여 코로나19라고 판단한 영상의 근거를 시각화하였다.

Grad-CAM은 CAM(Class Activation Mapping)[20]을 확장한 개념으로 어떠한 영상을 비정상 영상이라고 판단했을 때, 그 영상에서 비정상이라는 결과를 내는데 가장 많이 영향을 준 영역을 확률값으로 표현한 것이다. 표 4는 코로나19 흉부 X선이라고 판단한 영상에 Grad-CAM을 사용하여 히트맵과 바운딩 박스로 시각화한 것이다.

VI. 결 론


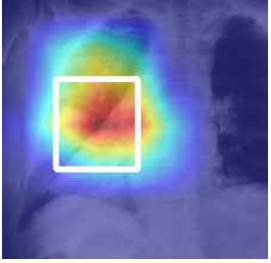

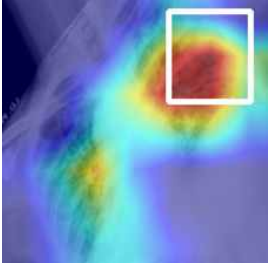

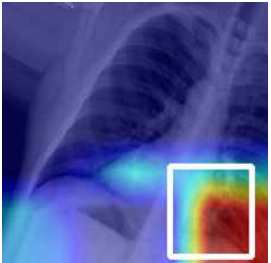

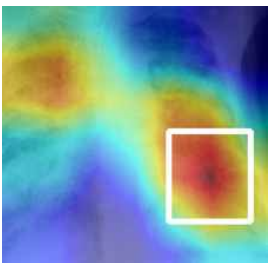
본 논문에서는 StackGAN++을 사용하여 흉부 X선 판독모델 학습에 필요한 충분한 수의 영상 데이터를 확보한 뒤, DenseNet으로 정상 환자와 코로나19 감염 환자를 이진 분류하는 모델을 제안하였다. 학습을 통해 판독모델의 정확도가 98%로 높은 성능을 가지는 것을 확인하였다. 그리고 설명 가능한 인공지능인 Grad-CAM을 사용해 판독모델의 신뢰성을 보장하여 해당 모델의 임상적 가치를 증명하였다.

따라서, 논문에서 제안한 판독모델은 코로나19 감염 여부에 대한 영상을 판독하는데 필요한 물리적 시간과 노력을 줄여 의료진에게는 업무 과중 부담 문제를 해결할 수 있고, 환자에게는 신속하고 정확한 검진결과를

제공할 수 있다.

더 나아가 코로나19 흉부 X선 영상 데이터가 누적됨에 따라 제안한 기법으로 재학습을 시킨다면 보다 높은 성능을 기대할 수 있을 것이다.

표 4. 코로나19 영상 Grad-CAM 사용 전후
Table 4. Before and After Using of Grad-CAM

코로나19 영상	히트맵 결과
	
	
	
	

References

- [1] L. Yao, et al, "Learning to diagnose from scratch by exploiting dependencies among labels", 2017. arXiv preprint arXiv:1710.10501
- [2] J. Kim, "An Analysis of the effect of Artificial Intelligence on Human Society", The Journal of the Convergence on Culture Technology, Vol. 5, No. 2, pp. 177-182, 2019. doi.org/10.17703/JCCT.2019.5.2.177
- [3] G. Litjens, et al, "A survey on deep learning in medical image analysis", Medical image analysis, Vol. 42, pp. 60-88, 2017. doi.org/10.1016/j.media.2017.07.005.
- [4] F. Provost, "Machine learning from imbalanced data sets 101", Proceedings of the AAAI'2000 workshop on imbalanced data sets, AAAI Press, Vol. 68, No. 2000, pp. 1-3, 2000
- [5] H. Zhang, et al, "Stackgan++: Realistic image synthesis with stacked generative adversarial networks", IEEE transactions on pattern analysis and machine intelligence, Vol. 41, No. 8, pp. 1947-1962, 2018
- [6] E. Tjoa, C. Guan, "A survey on explainable artificial intelligence (XAI): towards medical XAI", pp. 1-21, 2020. doi.org/10.1109/TNNLS.2020.3027314
- [7] I. Goodfellow, et al, "Generative adversarial nets", Advances in neural information processing systems, pp. 2672-2680, 2014
- [8] A. Radford, et al, "Unsupervised representation learning with deep convolutional generative adversarial networks", 2015. arXiv preprint arXiv:1511.06434
- [9] T. Karras, et al, "Progressive growing of gans for improved quality, stability, and variation", 2017. arXiv preprint arXiv:1710.10196
- [10] T. Karras, et al, "A style-based generator architecture for generative adversarial networks", Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 4401-4410, 2019
- [11] M. Mirza, S. Osindero, "Conditional generative adversarial nets", 2014. arXiv preprint arXiv:1411.1784
- [12] P. Isola, et al, "Image-to-image translation with conditional adversarial networks", Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 1125-1134, 2017
- [13] J. Y. Zhu, et al, "Unpaired image-to-image translation using cycle-consistent adversarial networks", Proceedings of the IEEE international conference on computer vision, pp. 2223-2232, 2017
- [14] G. Huang, et al, "Densely connected convolutional networks", Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 4700-4708, 2017
- [15] A. Krizhevsky, et al, "Imagenet classification with deep convolutional neural networks", Communications of the ACM, Vol. 60, No. 6, pp. 84-90, 2017. doi.org/10.1145/3065386
- [16] M. Kim, K. H. Kang, "Comparison of Neural Network Techniques for Text Data Analysis", International Journal of Advanced Culture Technology, Vol. 8, No. 2, pp. 231-238, 2020. doi.org/10.17703/IJACT.2020.8.2.231
- [17] K. He, et al, "Deep residual learning for image recognition", Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 770-778, 2016
- [18] P. Rajpurkar, et al, "CheXnet: Radiologist-level pneumonia detection on chest x-rays with deep learning", 2017. arXiv preprint arXiv:1711.05225
- [19] R. R. Selvaraju, et al, "Grad-cam: Visual explanations from deep networks via gradient-based localization", Proceedings of the IEEE international conference on computer vision, pp. 618-626, 2017. doi.org/10.1007/s11263-019-01228-7
- [20] B. Zhou, et al, "Learning deep features for discriminative localization", Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 2921-2929, 2016

※ 본 논문은 2020학년도 서울여자대학교 교내 연구비의 지원을 받았음(2020-0102).